

Аннотация

Работа посвящена исследованию задачи поиска сообществ в ориентированных взвешенных графах с помощью гедонического алгоритма. На данный момент гедонические игры были использованы только для кластеризации неориентированных графов. Основная цель данной работы - понять, как может быть устроено разбиение на сообщества вершин ориентированного графа. В результате исследования построен гедонический алгоритм поиска сообществ, исследована зависимость равновесного разбиения от числа ориентированных ребер. Часть результатов обоснована теоретически. Проведено сравнение полученного алгоритма с существующими алгоритмами кластеризации по модулярности и количеству кластеров в результирующем разбиении. Проведен статистический анализ распределений числа и размера полученных кластеров, численно исследована зависимость параметров этих распределений от числа ориентированных ребер. Алгоритм протестирован на нескольких моделях случайных графов, построена зависимость характеристик структуры сообществ от параметров модели графа.

Содержание

1. Аннотация	2
2. Введение	4
3. Теоретическое введение	6
3.1. Гедонические игры	6
3.2. Центральности	8
3.2.1. Betweenness betweenness.	8
3.2.2. Degree.	9
3.2.3. Closeness.	9
3.2.4. PageRank pagerankcent.	10
3.2.5. Статические веса.	10
3.2.6. Случайные веса.	10

Введение

Поиск сообществ в графах, рассматриваемый в данной работе, является одной из разновидностей кластеризации, относящейся к задачам обучения без учителя. В данной задаче рассматривается граф $G(V, E)$, где $V = \{1, \dots, N\}$ - множество вершин, а множество упорядоченных пар $E = \{(u, v) : u, v \in V\}$ - множество ребер. На множестве ребер задана функция $d : E \rightarrow [0, 1]$, являющаяся функцией веса. Необходимо разбить множество вершин на группы так, чтобы полученное разбиение удовлетворяло заданным требованиям. Разбиение графов на сообщества отличается от задачи кластеризации точек в метрическом пространстве тем, что метрика в данной задаче не вводится. Функция $d(u, v)$ в общем случае не задана для каждой пары точек и несимметрична, поэтому разбиение на сообщества ищется только на основе топологии графа и, возможно, весов ребер.

Задача кластеризации графов может возникнуть в совершенно разных областях и преследовать разные цели. К примеру, известно, что общение между процессорами происходит гораздо медленнее по сравнению с передачей данных внутри процессора, поэтому в компьютерных сетях это взаимодействие лучше минимизировать. Так как компьютерную сеть можно представить в виде невзвешенного неориентированного графа, задача сводится к тому, чтобы разбить вершины на группы так, что количество ребер между группами минимально. Поставленную задачу может решить алгоритм Ньюмана Newman2004.

Важным примером задачи выявления сообществ в ориентированных графах является задача распознавания отмывания денег ml. Для решения этой задачи ранее применялось обучение с учителем. На данный момент есть, например, алгоритм Louvain ml1, который находит сообщества в ориентированном взвешенном графе.

На данный момент из существующих алгоритмов поиска сообществ в графах можно выделить две группы:

1. Алгоритмы, оптимизирующие некоторую целевую функцию, зависящую от заданного разбиения вершин на сообщества. Эту функцию обычно называют модулярностью, ее определение будет дано в теоретическом введении.

2. Теоретико-игровые алгоритмы, в которых для каждой вершины, называемой агентом, вводится собственная функция прибыли, которую агент старается оптимизировать. Устойчивое разбиение агентов на сообщества, когда ни один агент не может увеличить свою прибыль, и будет искомым.

Кроме того, в обеих группах есть и алгоритмы, работающие только для неориентированных графов, и универсальные алгоритмы, работающие для любых графов. Примером алгоритма, максимизирующего модулярность, является уже упомянутый алгоритм Ньюмана, работающий для неориентированных графов. Алгоритм Louvain тоже максимизирует функцию, называемую модулярностью, работает для ориентированных графов и не является игровым алгоритмом. Теоретико-игровой алгоритм "label propagation" Raghavan ищет сообщества в ориентированных графах, причем прибыль агента - количество его out-соседей, лежащих с ним в одном сообществе. Алгоритм InfoMap infomap, кластеризующий ориентированные взвешенные графы, минимизирует среднюю длину случайного блуждания, закодированного с помощью кода Хаффмана. Пример теоретико-игрового алгоритма, кластеризующего ориентированные графы, можно найти здесь Balliu.

Среди теоретико-игровых алгоритмов кластеризации можно выделить гедонические алгоритмы clusteringhg. Строгое определение гедонической игры будет дано в теоретическом введении. Кратко, игра называется гедонической, если для агента выбор фиксированной стратегии зависит от того, какие еще агенты выбрали эту стратегию framework. На данный момент изучено несколько алгоритмов кластеризации неориентированных взвешенных графов clusteringhg. Задача кластеризации ориентированного графа формулируется только в работах на тему "Fractional Hedonic Games" fhg2017, но нигде не изучается. Гедонический алгоритм кластеризации ориентированного взвешенного графа может быть полезен, например, в упомянутой выше задаче распознавания отмывания денег. В связи с этим, целью данной работы является изучение кластеризации ориентированного взвешенного графа с помощью аппарата гедонических игр, построение соответствующего алгоритма и исследование его свойств, нахождение отличий равновесных разбиений на сообщества неориентированного и ориентированного графа. Также понять особенности полученного алгоритма может помочь сравнение с существующими алгоритмами кластеризации.

Теоретическое введение

3.1 Гедонические игры

Введем определение гедонической игры, которое будет использоваться на протяжении всего исследования.

Пусть есть множество агентов $\{1, \dots, N\}$, σ - некоторое разбиение агентов на сообщества, $\sigma = \{S_1, \dots, S_n, S_i \cap S_j = \emptyset, \cup_i S_i = \{1, \dots, N\}\}$. Агентов будем также называть игроками. Для каждого агента задана функция полезности $u_i(\sigma)$ (или, иначе, функция прибыли), зависящая от текущего разбиения. Пусть агенты могут свободно перемещаться между кластерами. В данной работе стратегией игрока будем называть сообщество, которое данный игрок выбирает. Задача состоит в том, чтобы отыскать оптимальные стратегии для каждого игрока: то есть, при выборе данной стратегии игрок имеет максимальную прибыль при фиксированных оптимальных стратегиях всех остальных игроков. В данной работе мы будем рассматривать некооперативные игры. Это означает, что два или более игрока не могут действовать согласованно, то есть каждый игрок выбирает стратегию, принимая во внимание только собственную прибыль ("selfish" players). Результирующее разбиение, в котором никакой игрок не хочет изменить стратегию, и будет искомым разбиением множества агентов на сообщества.

Будем называть игру гедонической, если функция полезности u_i каждого игрока зависит только от того, какие еще игроки входят в сообщество, которому принадлежит рассматриваемый игрок. При этом разбиение оставшихся вершин на сообщества никак не влияет на прибыль рассматриваемого игрока. С помощью некооперативных гедонических игр можно моделировать множество ситуаций, в которых агенты объединяются в сообщества, исходя из личных интересов. Впервые гедонические игры были введены и проанализированы в этой работе firsthg. Большинство работ по гедоническим играм посвящено изучению равновесия Нэша (набора оптимальных стратегий игроков, при которых никакой игрок не хочет изменить свою стратегию при фиксированных оптимальных стратегиях других игроков), а также нахождению оптимальных стратегий игроков, доказательству существования или отсутствия равновесия Нэша в различных игровых моделях core1, core2, core3.

Чтобы лучше понять, как могут быть устроены гедонические алгоритмы поиска сообществ, рассмотрим примеры конкретных алгоритмов и решаемых ими задач. Как и в метрических алгоритмах кластеризации, количество кластеров в некоторых теоретико-игровых алгоритмах известно заранее, а в других - нет. Приведем несколько существующих алгоритмов.

Кластеризацию первого типа в литературе часто называют "fixed clustering". Приведем пример такого алгоритма, кластеризующего полный взвешенный неориентированный граф. Назовем условно веса ребер графа "расстояниями". Пусть число кластеров известно заранее и равно k . В таком случае удобно формировать кластеры вокруг так называемых "центроидов представителей каждого из k кластеров. Введем "цену" кластера - сумму расстояний от всех агентов в данном кластере до его центроида. Тогда введем цену $c_v(C)$, которую платит агент v за нахождение в кластере C , как цену кластера C , разделенную поровну между его агентами. Теперь прибыль игрока можно считать равной $-c_v$. Набор стратегий игрока - k чисел, обозначающих номера кластеров, которые можно выбрать. На каждом шаге игроку v нужно выбрать такой кластер C , что величина $c_v(C \cup v)$ минимальна, где c_v - "цена которую платит v при заданном разбиении на сообщества. Оказывается, что агенту нужно минимизировать собственное расстояние до центроида clusteringhg. Примером применения такого алгоритма является организация передачи данных между устройствами, минимизирующая энергетические затраты: устройства объединяются в кластеры согласно приведенному алгоритму, и передача данных осуществляется только между агентом и центроидом одного кластера и между центроидами.

Кластеризация второго типа имеет еще более широкое применение, так как зачастую количество кластеров заранее неизвестно. Пусть известны только "отношения" между агентами - веса ребер графа. Предположим, что между агентами теперь задана метрика: $d : (v, v) \rightarrow [0, 1]$. Пусть $d(u, v)$ обозначает "меру различия" объектов u и v : если $d(u, v)$ близко к нулю, то объекты похожи, а если, напротив, $d(u, v)$ близко к единице, то объекты очень разные. Пусть также каждый агент v имеет вес w_v , обозначающий "меру влияния" на остальных. Пусть агенты хотят быть в одном кластере с близкими им объектами с большим весом, но отделиться непохожих на них агентов с маленьким весом. С помощью функции полезности агента можно это учесть clusteringhg. Так можно решать любую задачу, в которой, например, агенты хотят объединиться "по интересам отдалившись от тех, кто на них не похож.

Второй пример важен для нас в данной работе, так как мы будем рассматривать именно этот тип кластеризации, когда количество кластеров заранее неизвестно. Кроме того, мы будем использовать похожую функцию полезности, но функция веса ребер графа $d(u, v)$ уже не будет метрикой, и даже не будет определена для всех пар вершин.

Соответственно, $d(u, v)$ уже нельзя считать расстоянием. Веса вершин в нашей работе также будут использоваться, но будет рассмотрено большое их количество, и зависеть они будут от топологии графа, чего в рассмотренной выше постановке быть не может. Про веса вершин будет подробно рассказано в следующей части теоретического введения.

3.2 Центральности

Понимание роли каждого элемента системы является важным шагом в изучении поведения этой системы. Мы будем рассматривать кластеризацию ориентированных графов (или, иначе, сети) с различной топологией, а значит, разные вершины в такой сети будут иметь разное положение относительно всех остальных. Если рассматривать ребро графа как некоторую характеристику "влияния" одной вершины на другую, то такие характеристики, как количество out-соседей, веса out-ребер, а также то, каким "влиянием" обладают сами out-соседи вершины, может характеризовать "важность" вершины в сети. Такая мера "важности" вершины графа называется мерой центральности. Мер центральности можно ввести очень много. Рассмотрим здесь те, которые будем использовать для определения важности вершин в данной работе.

3.2.1 Betweenness betweenness.

Эта мера широко используется в социальных сетях. Она основана на предположении о том, что, если человек в некоторой социальной группе имеет некоторое "центральное" положение, соединяя много пар других людей, то он "важен" для этой группы. Этот человек может в какой-то мере контролировать общение людей, связанных между собой через него кратчайшим путем. В терминах сети, если вершина лежит на большом количестве кратчайших путей между другими вершинами, то мера центральности этой вершины должна быть высокой. Рассмотрим вершины графа i и j . Пусть число всех кратчайших путей (называемых также геодезическими) из i в j равно g_{ij} . Тогда вероятность, что i выберет один из этих путей p для передачи информации j , есть g_{ij}^{-1} . Тогда для каждой вершины k графа обозначим как $g_{ij}(k)$ число кратчайших путей из i в j , содержащих k . Тогда мера центральности k вводится следующим образом:

$$b_{ij}(k) = \frac{g_{ij}(k)}{g_{ij}}, \quad (1)$$

$$C_B(k) = \sum_{i < j} b_{ij}(k), \quad (2)$$

где $b_{ij}(k)$ - вероятность того, что на выбранном пути передачи информации из i в j содержится k .

3.2.2 Degree.

В некоторых сетях удобно ввести меру центральности так, чтобы она зависела от степени вершины. Например, рассмотрим распространение инноваций в социальных сетях. Чем больше степень вершины, тем больше вершин могут "заразиться" от данной (принять инновацию). В нашей задаче граф ориентированный, поэтому мера центральности вершины будет пропорциональна числу исходящих ребер (out-степени вершины). Обозначим через d_{max} максимальную out-степень вершины в графе. Тогда меру центральности вершины i будем считать так:

$$C_d(i) = \frac{\sum_{j \neq i} \delta_{ij}}{d_{max}}, \quad (3)$$

$$d_{max} = \max_i \left\{ \sum_{j \neq i} \delta_{ij} \right\}, \quad (4)$$

где $\delta_{ij} = 0$, если ребра $i \rightarrow j$ нет, $\delta_{ij} = 1$, если ребро $i \rightarrow j$ есть.

Также рассмотрим weighted (взвешенную) degree-центральность, в которой важность вершины будет зависеть не только от числа исходящих ребер, но и от их веса (например, в уже рассмотренной социальной сети наличие связи не говорит о том, что информация точно будет передана; вместо этого, можно задать вес ребра как некоторую величину, оценивающую вероятность передачи информации по ребру). Теперь нам потребуется максимальная по всем вершинам сумма весов исходящих ребер в графе: w_{max} . Мера центральности вершины i :

$$C_{wd}(i) = \frac{\sum_{j \neq i} \delta_{ij} \cdot w_{ij}}{w_{max}}, \quad (5)$$

$$w_{max} = \max_i \left\{ \sum_{j \neq i} \delta_{ij} \cdot w_{ij} \right\}, \quad (6)$$

где w_{ij} - вес ребра $i \rightarrow j$.

3.2.3 Closeness.

Эта мера центральности, как нетрудно понять из названия, характеризует "близость" вершины ко всем остальным вершинам графа. Пусть d_{ij} - число ребер в кратчайшем пути от вершины i до вершины j . Тогда рассмотрим меру:

$$D_c(i) = \sum_{j \neq i} d_{ij}. \quad (7)$$

Указанная величина имеет противоположный смысл: чем меньше сумма кратчайших расстояний от данной вершины до всех остальных, тем более она "центральна". Значит,

меру центральности вершины i можно ввести как величину, обратную $D_c(i)$:

$$C_c(i) = \frac{1}{\sum_{j \neq i} d_{ij}}. \quad (8)$$

В уже рассмотренной задаче распространения инноваций closeness-центральность может характеризовать скорость распространения инновации по сети от заданного узла.

3.2.4 PageRank pagerankcent.

Центральность вершины в ориентированном графе можно измерить с помощью известного алгоритма ранжирования страниц, соответствующих некоторому поисковому запросу. Согласно алгоритму PageRank, вес страницы A тем больше, чем больше вес страниц B , на нее ссылающихся. Также чем больше страниц B ссылаются на данную страницу A , тем больше вес страницы A . Формулу задают так:

$$PR(A) = (1 - d) + d \cdot \left(\frac{PR(T_1)}{C(T_1)} + \dots + \frac{PR(T_n)}{C(T_n)} \right), \quad (9)$$

где $PR(A)$ - вычисляемый вес страницы A , d - коэффициент "затухания" (необходим для того, чтобы циклы, появляющиеся, например, если A ссылается на B и B ссылается на A , не "стягивали" на себя всю центральность), $PR(T_i)$ - вес страницы T_i , ссылающейся на A , $C(T_i)$ - число ссылок на странице T_i , n - число страниц T_i , ссылающихся на A pagerank.

3.2.5 Статические веса.

Для теоретического исследования алгоритма понадобятся статические веса вершин, которые в работе будут иногда обозначаться static. Это означает, что веса всех вершин одинаковы и равны $\frac{1}{2}$.

3.2.6 Случайные веса.

Важности вершин в реальных задачах не всегда зависят от топологии графа: они могут быть получены, например, на основании экспертного мнения. Однако, кластеризация такого графа все еще будет зависеть от топологии. Для изучения такого случая можно присвоить вершинам случайные (random) веса, лежащие на отрезке $[0, 1]$.